


UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

(Universidad del Perú, DECANA DE AMÉRICA)

Facultad de Ciencias Matemáticas

Escuela Profesional de Estadística.



Autores:

Gonzales Bustamante Jesús

Romero Castillo Cielo Antonella

Sarmiento Arriaga Rich Albert

Docente:

MISAEEL ERIKSON MAGUIÑA PALMA

Análisis de mortalidad en el Perú (2019-2024)

Jesús Gonzales Bustamante; Cielo Antonella Romero Castillo; Rich Albert

Sarmiento Arriaga; Misael Erikson Maguiña Palma

¹ Universidad Mayor de San Marcos, 5to Ciclo, (0000-0003-0843-4156), jesus.gonzales9@unmsm.edu.pe

² Universidad Mayor de San Marcos, 5to Ciclo, (0009-0004-0787-324X), cielo.romero@unmsm.edu.pe

³ Universidad Mayor de San Marcos, 5to Ciclo, (0009-0005-0328-3733), rich.sarmiento@unmsm.edu.pe

Resumen

El presente trabajo integrador analizó la dinámica de las defunciones registradas en el Perú durante el periodo 2019-2024. Para ello, se extrajo y procesó la base de datos del SINADEF mediante la implementación de un flujo ETL estructurado en Python y PostgreSQL. La investigación se enmarcó en un enfoque cuantitativo, con un diseño no experimental y un alcance descriptivo-analítico. La preparación de los datos contempló la depuración exhaustiva de registros y la normalización de variables geográficas utilizando el estándar UBIGEO, lo que permitió incorporar una clasificación precisa por región natural. Como resultado, se consolidó una base de datos final validada de 886 058 registros, abarcando 25 departamentos del país.

Los hallazgos revelaron una marcada concentración territorial en la costa (70.35%), posicionando a Lima como el departamento con mayor volumen de defunciones, seguido por La Libertad, Piura y Arequipa. A nivel demográfico, se evidenció un predominio de fallecimientos masculinos (55.66%) y una alta vulnerabilidad en la cohorte de adultos mayores de 61 años, la cual representó el 69.95% del total. Finalmente, los datos procesados se operativizaron a través del diseño de un *dashboard* interactivo en Power BI y la construcción de un modelo de clasificación supervisada (árbol de decisión), el cual logró discriminar los registros de individuos ancianos y no ancianos con una exactitud general del 67.90%.

Palabras clave: mortalidad, defunciones, SINADEF, flujo ETL, Power BI, árbol de decisión.

Introducción

El análisis de defunciones constituye una herramienta relevante para describir el comportamiento de la mortalidad registrada y apoyar la toma de decisiones en salud pública. En el contexto peruano, la disponibilidad de registros administrativos permite identificar patrones temporales, territoriales y demográficos que facilitan la construcción de indicadores y tableros de inteligencia de negocios. En este trabajo se empleó información de defunciones registradas y se desarrolló un proceso de integración de datos orientado al análisis descriptivo y a la visualización interactiva.

El periodo seleccionado para este estudio (2019-2024) reviste una importancia histórica y epidemiológica sin precedentes. Este lapso abarca el escenario basal previo a la emergencia sanitaria global, el impacto disruptivo de la pandemia de COVID-19 que alteró drásticamente los patrones, causas y volúmenes de mortalidad en el país y la subsecuente

etapa de estabilización. Comprender la dinámica de las defunciones a lo largo de este ciclo es vital para evaluar cómo las crisis sanitarias impactan de manera diferenciada en las distintas regiones naturales y estratos demográficos del país.

Asimismo, frente al volumen masivo de información que registra el sistema de salud a nivel nacional, los enfoques analíticos tradicionales resultan insuficientes. La consolidación de bases de datos granulares exige la adopción de herramientas de Inteligencia de Negocios (BI) y técnicas de aprendizaje automático (*Machine Learning*). Implementar estas tecnologías permite transformar datos crudos en conocimiento accionable, facilitando a los tomadores de decisiones la identificación rápida de perfiles de riesgo, la focalización de recursos territoriales y la formulación de políticas públicas basadas en evidencia."

Formulación del problema

Problema general: ¿De qué manera el análisis multidimensional de los registros administrativos de defunciones en el Perú, durante el periodo 2019-2024, permite identificar patrones espaciotemporales, demográficos y causales que sirvan como insumo para la toma de decisiones en salud pública?

Problemas específicos:

- ¿Cuál fue la evolución temporal de las defunciones registradas y qué variaciones volumétricas se observaron año tras año?
- ¿De qué forma se concentró la mortalidad según la distribución geográfica por departamentos y regiones naturales?
- ¿Cuáles fueron las características demográficas predominantes, según sexo y grupo de edad, en los registros analizados?
- ¿Qué diagnósticos destacaron como causas principales de muerte y cuál fue su nivel de concentración en la población general?
- ¿Qué tipologías predominaron dentro del subconjunto de defunciones clasificadas como muertes violentas?

- ¿En qué medida un modelo predictivo basado en árboles de decisión puede clasificar si un registro corresponde a un adulto mayor, a partir de sus atributos sociodemográficos y administrativos?

Objetivos

Objetivo general

Analizar la dinámica temporal, espacial y demográfica de las defunciones registradas en el Perú durante el periodo 2019-2024, mediante la implementación de un ecosistema de Inteligencia de Negocios (ETL, PostgreSQL y Power BI) que permita identificar patrones críticos para la toma de decisiones en salud pública.

Objetivos específicos

- **Describir** la evolución temporal de las defunciones registradas anualmente para identificar variaciones y picos anómalos durante el periodo de estudio.
- **Comparar** la distribución geográfica espacial agrupando los registros por departamentos y regiones naturales (costa, sierra y selva).
- **Determinar** el perfil demográfico predominante de las defunciones considerando las variables de sexo y grupo de edad.
- **Identificar** las causas principales de muerte a nivel nacional, consolidando los diagnósticos textuales y códigos CIE-X mediante un análisis de Pareto.
- **Examinar** la incidencia y tipología de las muertes clasificadas como violentas dentro del conjunto de registros.
- **Desarrollar y evaluar** un modelo analítico de clasificación supervisada (árbol de decisión) para predecir si un registro corresponde a la cohorte de adultos mayores, basándose en sus características sociodemográficas y administrativas.

Método

El presente estudio se enmarcó en una investigación de tipo aplicada, bajo un enfoque estrictamente cuantitativo. El diseño metodológico empleado fue no experimental, de corte transversal-retrospectivo y con un alcance descriptivo-analítico. Como unidad de análisis se

definió cada registro individual de defunción proveniente de una fuente de datos secundaria, abarcando el periodo comprendido entre los años 2019 y 2024.

Para la depuración y consolidación de la muestra final, se establecieron parámetros de selección específicos. Como **criterios de inclusión**, se consideraron únicamente aquellos registros cuyo país de domicilio declarado fuera el Perú, que contaran con un departamento territorialmente reconocido y poseyeran una región natural asignada de manera unívoca. Por el contrario, como **criterios de exclusión**, se descartaron todos los registros que presentaran inconsistencias o carecieran de una correspondencia geográfica válida, garantizando de este modo la idoneidad y calidad de los datos para el análisis a nivel nacional.

Proceso por pasos:

Procedimiento de integración y análisis de datos

El desarrollo de la investigación se estructuró bajo un flujo de trabajo de Inteligencia de Negocios, siguiendo las fases de Extracción, Transformación, Carga (ETL) y Análisis Visual:

Fase 1: Extracción de datos (Extract)

Se realizó la ingesta de la información desde fuentes heterogéneas. Como insumo principal se cargó el archivo de defunciones en formato CSV (`fallecidos_sinadef.csv`). Para garantizar la homologación espacial, se integraron dos archivos auxiliares en formato Excel: un catálogo de ubicación (`UBIGEO.xlsx`) y un diccionario de correspondencia territorial (`tabla_region_departamento.xlsx`).

Fase 2: Transformación y limpieza (Transform)

El procesamiento y depuración de la información se ejecutó en el entorno de desarrollo Jupyter Notebook utilizando el lenguaje Python. En esta etapa se aplicaron rutinas de calidad de datos que incluyeron:

- Normalización de la nomenclatura de columnas y estandarización de cadenas de texto.
- Formateo de los campos de fecha y validación de la variable de edad en años exactos.
- Categorización de los registros mediante la creación de grupos de edad, homologación de la causa principal de defunción y clasificación del tipo de muerte (violenta o natural) y condición de necropsia.
- Cruce de los registros con los catálogos geográficos para asignar unívocamente el departamento y la región natural correspondiente.

Fase 3: Carga y modelado dimensional (Load)

El conjunto de datos transformado fue migrado a un motor de base de datos relacional en PostgreSQL. Para asegurar una arquitectura escalable, se diseñaron tres esquemas lógicos:

Esquema Staging: utilizado como área de preparación y transición de datos temporales.

Esquema DW (Data Warehouse): repositorio central donde se consolidó la tabla de hechos principal (dw.fact_defunciones) conformada por 886 058 registros, junto con sus respectivas tablas de dimensiones geográficas (dw.dim_ubigeo, dw.dim_region_natural).

Esquema Mart (Data Mart): capa orientada al consumo, donde se generaron vistas analíticas pre-agregadas (ej. segmentación de departamentos, análisis de Pareto de causas, matriz de confusión e importancia de variables del modelo).

Fase 4: Análisis predictivo y visualización

Sobre la base consolidada, se entrenó un algoritmo de aprendizaje supervisado (árbol de decisión) orientado a la clasificación dicotómica de la población (Anciano vs. No anciano). Finalmente, se estableció una conexión directa entre PostgreSQL y Microsoft Power BI para la construcción de un dashboard analítico compuesto por cinco vistas interactivas (resumen general, perfil demográfico, evolución temporal, muertes violentas y desempeño del modelo), facilitando así la interpretación gerencial de los resultados.

Tabla 1. Fuentes, herramientas y producto del proceso ETL

Componente	Descripción
Fuente principal	fallecidos_sinadef.csv
Archivo auxiliar geográfico	UBIGEO.xlsx
Archivo auxiliar regional	tabla_region_departamento.xlsx
Herramientas	Python/Jupyter, PostgreSQL y Power BI
Base de datos final	dw.fact_defunciones con 886 058 registros válidos

El proceso ETL se desarrolló en Jupyter Notebook. En la extracción se cargaron los archivos CSV y Excel. En la transformación se normalizaron nombres de columnas, textos, fechas, edad en años, grupos de edad, ubicación, causa principal, muerte violenta y necropsia. En la carga se crearon los esquemas staging, dw y mart en PostgreSQL, se cargó la tabla principal de hechos y se generaron tablas/vistas analíticas para Power BI.

Tabla 2. Objetos cargados en PostgreSQL después del ETL

Objeto en PostgreSQL	Registros
dw.fact defunciones	886 058
dw.dim ubigeo	1 873
dw.dim region natural	25
mart.segmentacion departamentos	25
mart.pareto causas	56 853
mart.metricas arbol edad	5
mart.matriz confusion arbol edad	2
mart.importancia arbol edad	15

Las técnicas aplicadas fueron estadística descriptiva, segmentación por cuartiles de departamentos según concentración de defunciones, análisis de Pareto de causas principales y un modelo supervisado de árbol de decisión para clasificar defunciones de ancianos y no ancianos. Se consideraron criterios éticos al trabajar con datos secundarios y agregados, sin identificación personal de individuos.

Resultados

Estadísticos descriptivos clave

Total de defunciones	Edad promedio	Departamentos analizados	Muertes violentas
886 058	67 años	25	36 053

La base final validada estuvo conformada por 886 058 registros de defunción del periodo 2019-2024. El promedio de edad fue de aproximadamente 67 años y se analizaron 25 departamentos del Perú.

Tabla 3. Evolución anual de defunciones registradas

Año	Defunciones	Variación anual (%)
2 019	114 378	-
2 020	215 784	88.66 %
2 021	247 718	14.80 %
2 022	158 140	-36.16 %
2 023	110 432	-30.17 %
2 024	39 606	-64.14 %




Figura 1. Evolución anual de defunciones registradas, 2019-2024.

El mayor volumen anual se observó en 2021 con 247 718 defunciones registradas. En 2020 se evidenció un incremento de 88.66% respecto a 2019, mientras que después de 2021 se observó una reducción progresiva hasta 2024.

Tabla 4. Defunciones por región natural

Región natural	Defunciones	Porcentaje
Costa	623 385	70.35 %
Sierra	202 731	22.88 %
Selva	59 942	6.77 %

Defunciones por región natural




Figura 2. Participación porcentual de defunciones por región natural.

La costa concentró 623 385 registros, equivalentes al 70.35% del total. La sierra representó 22.88% y la selva 6.77%, lo cual muestra una alta concentración de registros en departamentos costeros.

Tabla 5. Top 10 departamentos con mayor número de defunciones

Departamento	Defunciones
Lima	329 091
La Libertad	56 920
Piura	47 606
Arequipa	46 934
Junín	39 279
Puno	38 996
Áncash	38 976
Cusco	35 401
Ica	32 441
Cajamarca	25 581




Figura 3. Top 10 departamentos por número de defunciones.

Lima presentó 329 091 registros, muy por encima del resto de departamentos. Luego se ubicaron La Libertad, Piura, Arequipa, Junín y Puno. Esta concentración justifica el uso de una segmentación por niveles para el análisis territorial.

Tabla 6. Defunciones según sexo

Sexo	Defunciones	Porcentaje
Masculino	493 152	55.66 %
Femenino	392 839	44.34 %
Indeterminado	63	0.01 %
Sin registro	4	0.00 %

Tabla 7. Defunciones según grupo de edad

Grupo de edad	Defunciones	Porcentaje
Anciano (61+)	619 762	69.95 %
Adulto (18-60)	227 305	25.65 %
Bebé (0-3)	25 985	2.93 %
Niño (4-12)	6 838	0.77 %
Adolescente (13-17)	6 144	0.69 %
No especificado	24	0.00 %

El perfil demográfico evidenció mayor participación de registros masculinos (55.66%) frente a femeninos (44.34%). Por edad, el grupo de ancianos de 61 años a más concentró 619 762 registros, lo que representó el 69.95% del total.

Tabla 8. Top 10 causas principales agrupadas por texto registrado

Causa principal	Defunciones
Insuficiencia respiratoria aguda	168 651
Insuficiencia respiratoria	113 832
Falla multiorgánica	37 181
Infarto agudo de miocardio	23 104
Infarto agudo del miocardio	18 759
Shock séptico	16 360
Sepsis	15 160
Paro cardiorrespiratorio	12 924
Choque séptico	10 191
Paro respiratorio	9 633




Figura 4. Principales causas registradas en la causa A.

Las principales causas registradas estuvieron asociadas a insuficiencia respiratoria, falla multiorgánica, infarto agudo de miocardio, shock séptico, sepsis y paro cardiorrespiratorio. Se observó que algunas causas se registraron con variaciones textuales, por lo que el análisis mantuvo la trazabilidad del texto original y del código CIE-X cuando estuvo disponible.

Tabla 9. Pareto de causas principales con código CIE-X

Causa principal / CIE-X	Defunciones	Porcentaje	Porcentaje acumulado
Insuficiencia respiratoria aguda / J960	149 620	20.50 %	20.50 %
Insuficiencia respiratoria / J960	53 809	7.37 %	27.87 %
Insuficiencia respiratoria / J969	43 227	5.92 %	33.79 %
Infarto agudo de miocardio / I219	17 861	2.45 %	36.24 %
Infarto agudo del miocardio / I219	17 382	2.38 %	38.62 %
Sepsis / A419	9 201	1.26 %	39.88 %
Paro respiratorio / R092	9 171	1.26 %	41.14 %
Insuficiencia respiratoria aguda / J969	7 669	1.05 %	42.19 %
Choque séptico / R572	7 199	0.99 %	43.18 %
Paro cardiorrespiratorio / I469	6 129	0.84 %	44.02 %

El análisis de Pareto mostró que la causa "Insuficiencia respiratoria aguda / J960" concentró 20.50% del total de causas registradas en la causa principal. Las diez primeras combinaciones causa-CIE-X acumularon 44.02%, lo que confirma una concentración relevante de registros en pocas categorías.

Muertes violentas y necropsia

Tabla 10. Casos por tipo de muerte violenta

Tipo de muerte violenta	Casos
Accidente de tránsito	11 126
No se conoce	9 052
Homicidio	6 502
Otro accidente	5 002
Suicidio	3 230
Accidente de trabajo	1 141




Figura 5. Distribución de casos por tipo de muerte violenta.

Tabla 11. Evolución anual de muertes violentas

Año	Casos de muerte violenta
2 019	7 292
2 020	5 762
2 021	7 441
2 022	7 975
2 023	5 582
2 024	2 001

Se identificaron 36 053 registros clasificados como muertes violentas. El tipo más frecuente fue accidente de tránsito, seguido de registros clasificados como no se conoce, homicidio, otro accidente, suicidio y accidente de trabajo. Asimismo, se registraron aproximadamente 47 mil casos con necropsia realizada.

Segmentación territorial por cuartiles

Tabla 12. Segmentación descriptiva de departamentos por concentración de defunciones

Departamento	Región	Defunciones	Nivel
Lima	Costa	329 091	Muy alta concentración
La Libertad	Costa	56 920	Muy alta concentración
Piura	Costa	47 606	Muy alta concentración
Arequipa	Costa	46 934	Muy alta concentración
Junín	Sierra	39 279	Muy alta concentración
Puno	Sierra	38 996	Muy alta concentración
Áncash	Costa	38 976	Alta concentración
Cusco	Sierra	35 401	Alta concentración
Ica	Costa	32 441	Alta concentración
Cajamarca	Sierra	25 581	Alta concentración
Callao	Costa	25 437	Alta concentración
Lambayeque	Costa	23 499	Alta concentración
Huánuco	Sierra	19 960	Media concentración
Loreto	Selva	18 614	Media concentración
San Martín	Selva	18 243	Media concentración
Ayacucho	Sierra	14 595	Media concentración
Ucayali	Selva	12 766	Media concentración
Huancavelica	Sierra	12 149	Media concentración
Apurímac	Sierra	11 351	Baja concentración
Tacna	Costa	9 614	Baja concentración
Tumbes	Costa	7 378	Baja concentración
Amazonas	Selva	5 749	Baja concentración
Moquegua	Costa	5 489	Baja concentración
Pasco	Sierra	5 419	Baja concentración
Madre de Dios	Selva	4 570	Baja concentración

La segmentación por cuartiles permitió clasificar los departamentos en niveles de baja, media, alta y muy alta concentración de defunciones. Lima, La Libertad, Piura, Arequipa, Junín y Puno conformaron el grupo de muy alta concentración. Esta clasificación se empleó como insumo para el dashboard territorial.

Dashboard en Power BI

El dashboard se organizó en cinco vistas: resumen general, perfil demográfico, evolución y causas principales, análisis de muertes violentas y modelo analítico. La construcción visual se realizó a partir de la tabla dw.fact_defunciones y de vistas del esquema mart para resultados agregados y métricas del modelo.




Figura 6. Captura de la vista Resumen general del dashboard en Power BI.

Modelo analítico: árbol de decisión

Para incorporar una técnica de aprendizaje supervisado se construyó un árbol de decisión orientado a clasificar si una defunción correspondía a una persona anciana o no anciana. La variable objetivo se generó a partir del grupo de edad, considerando como anciano a los registros de 61 años a más. Las variables predictoras incluyeron sexo, región natural, departamento, tipo de seguro, tipo de lugar, necropsia y causa principal agrupada. Se evitó usar la edad numérica como predictor directo para no introducir una relación trivial con la variable objetivo.

Tabla 13. Resumen técnico del modelo supervisado

Componente	Valor
Algoritmo	Árbol de decisión
Variable objetivo	Anciano / No anciano
Registros del modelo	886 058
Variables predictoras codificadas	63 variables después de dummies
Entrenamiento	620 240 registros
Prueba	265 818 registros
Exactitud general	67.90%

Tabla 14. Métricas de clasificación del árbol de decisión

Clase	Precisión	Recall	F1-score	Soporte
No anciano	47.10 %	55.19 %	50.82 %	79 889
Anciano	79.21 %	73.36 %	76.18 %	185 929
Macro promedio	63.15 %	64.28 %	63.50 %	265 818
Promedio ponderado	69.56 %	67.90 %	68.56 %	265 818

Tabla 15. Matriz de confusión del modelo

Clase real	Predicho no anciano	Predicho anciano
Real no anciano	44 089	35 800
Real anciano	49 524	136 405

Tabla 16. Variables más importantes del modelo

Variable	Importancia
Necropsia realizada	0.409
Tipo de lugar: domicilio	0.260
Tipo de seguro: SIS	0.202
Tipo de seguro: ignorado	0.060
Región natural: selva	0.021
Sexo masculino	0.014
Causa: otras causas	0.011
Tipo de lugar: EESS	0.009
Región natural: sierra	0.005
Tipo de seguro: usuario	0.005




Figura 7. Importancia de variables del árbol de decisión.

El modelo alcanzó una exactitud de 67.90%. La clase Anciano presentó precisión de 79.21%, recall de 73.36% y F1-score de 76.18%, lo que indica mejor desempeño para identificar defunciones de adultos mayores que para la clase no anciano. Las variables de mayor importancia fueron necropsia realizada, tipo de lugar domicilio, tipo de seguro SIS y tipo de seguro ignorado. Estos resultados representan patrones asociados en los datos y no relaciones causales.

Discusión

Los hallazgos de esta investigación corroboran una marcada asimetría en la distribución espacial de la mortalidad, con una evidente concentración de defunciones en la región costera y, de manera desproporcionada, en el departamento de Lima. Este fenómeno responde principalmente al tamaño poblacional, la dinámica de centralización urbana y la concentración de servicios de salud en la capital. Sin embargo, se subraya como consideración metodológica que estos conteos representan frecuencias absolutas y no el riesgo real de mortalidad poblacional. Para estimar dicho riesgo y realizar comparaciones transversales equitativas entre departamentos, es mandatorio que futuros estudios incorporen estimaciones poblacionales anuales que operen como denominador.

Respecto al perfil demográfico, el predominio sostenido de defunciones en la cohorte de adultos mayores coincide con la alta vulnerabilidad biológica e inmunológica inherente a las edades avanzadas, acentuada además por una mayor letalidad en individuos de sexo masculino. En el ámbito clínico, la alta incidencia de causas principales genéricas, tales como la insuficiencia respiratoria y las afecciones relacionadas con la falla multiorgánica, sugiere un reto latente en la calidad del registro original. Esta concentración evidencia la necesidad urgente de revisar las pautas de certificación médica y aplicar técnicas más rigurosas de normalización textual de los diagnósticos para optimizar la trazabilidad en futuros análisis epidemiológicos.

Desde una perspectiva metodológica, el análisis de las muertes violentas permitió aislar exitosamente un subconjunto crítico, destacando la prevalencia de accidentes de tránsito, homicidios y suicidios. Por otro lado, la segmentación territorial demostró que las técnicas de agrupación determinísticas basadas en cuartiles resultan mucho más interpretables y robustas que algoritmos no supervisados como *K-Means* para este conjunto de datos, debido a la fuerte distorsión (valor atípico) que introduce el volumen de registros en Lima. Finalmente, aunque el modelo supervisado (árbol de decisión) presentó un desempeño de exactitud moderado, su implementación logró su propósito principal: demostrar la viabilidad y el valor agregado de integrar algoritmos de aprendizaje automático dentro de un flujo integral de inteligencia de negocios.

Conclusiones

- Se logró consolidar una arquitectura de datos robusta mediante el proceso ETL, lo que permitió integrar y estandarizar exitosamente la información de defunciones con los catálogos de UBIGEO y regiones naturales, obteniendo una base final validada de 886 058 registros para el periodo 2019-2024.
- El análisis longitudinal evidenció un comportamiento atípico en la evolución de la mortalidad, alcanzando un pico máximo histórico de registros en el año 2021, seguido de una fase de estabilización y reducción progresiva durante los años 2022, 2023 y 2024.

- La distribución territorial reflejó una profunda asimetría demográfica e institucional, donde la región costa concentró el 70.35% del total de las defunciones, posicionando a Lima, de manera indiscutible, como el departamento con mayor volumen de incidencia.
- El perfil demográfico predominante en los registros de mortalidad está altamente concentrado en la cohorte de adultos mayores (61 años a más), la cual representó el 69.95% de los casos, sumado a una mayor prevalencia de fallecimientos en individuos de sexo masculino (55.66%).
- Las defunciones por causas clínicas se agruparon mayoritariamente en diagnósticos genéricos y severos, destacando la insuficiencia respiratoria, la falla multiorgánica, el infarto agudo de miocardio, la sepsis y el shock séptico.
- El aislamiento del subconjunto de muertes violentas (36 053 casos) permitió identificar que la principal tipología de riesgo no natural en el país corresponde a los accidentes de tránsito, seguidos por eventos no determinados, homicidios y suicidios.
- Desde una perspectiva predictiva, el modelo supervisado (árbol de decisión) demostró la viabilidad de integrar algoritmos de clasificación en entornos de Inteligencia de Negocios. Aunque obtuvo una exactitud general moderada (67.90%), demostró una alta capacidad para identificar correctamente a la clase mayoritaria (Anciano), alcanzando un *F1-score* del 76.18%.
- Como línea de trabajo futuro, resulta indispensable incorporar las proyecciones poblacionales anuales del INEI por departamento, a fin de transicionar de un análisis de frecuencias absolutas hacia el cálculo de tasas de mortalidad, permitiendo así medir el riesgo epidemiológico real de los territorios.

Referencias

Instituto Nacional de Estadística e Informática. (s. f.). Estadísticas de población y vivienda del Perú. INEI.

Ministerio de Salud del Perú. (s. f.). Sistema Informático Nacional de Defunciones (SINADEF). MINSA.

Organización Mundial de la Salud. (2019). Clasificación Internacional de Enfermedades, 10.^a revisión (CIE-10). OMS.

Organisation for Economic Co-operation and Development & Eurostat. (2018). Oslo Manual 2018: Guidelines for collecting, reporting and using data on innovation (4th ed.). OECD Publishing.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

Microsoft. (s. f.). Documentación de Power BI y Power Query para conexiones a bases de datos PostgreSQL. Microsoft Learn.

Anexos

Anexo A. Evidencia del proceso en PostgreSQL


Se crearon los esquemas staging, dw y mart. Además, se implementó la tabla de control dw.control_etl para registrar eventos del proceso. Fragmento SQL utilizado:

```
CREATE SCHEMA IF NOT EXISTS staging;
CREATE SCHEMA IF NOT EXISTS dw;
CREATE SCHEMA IF NOT EXISTS mart;
SELECT schema_name
FROM information_schema.schemata
WHERE schema_name IN ('staging', 'dw', 'mart')
ORDER BY schema_name;
CREATE TABLE IF NOT EXISTS dw.control_etl (
    id_control SERIAL PRIMARY KEY,
    nombre_proceso VARCHAR(100),
    fecha_ejecucion TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
    estado VARCHAR(50),
    observacion TEXT
);
SELECT * FROM dw.control_etl;
INSERT INTO dw.control_etl (
    nombre_proceso,
```

```
estado,
observacion
)
VALUES (
'Preparación de base de datos',
'Correcto',
'Se crearon los esquemas staging, dw y mart para el proyecto SINADEF.'
);
```

Anexo B. Vistas construidas en Power BI

Tabla 17. Vistas en Power BI



Perfil demográfico de las defunciones

Distribución de defunciones según sexo, grupo de edad, edad promedio y tipo de seguro.

Año
Todas

Región
Todas

Sexo
Todas

Grupo de edad
Todas


Tipo de seguro
Todas

Total de Defunciones
886 mil


Promedio de edad
67

Muerte Violenta
36 mil


Total de defunciones por tipo de seguro



Defunciones por sexo



Defunciones por grupo de edad y sexo



Evolución y causas principales de defunción

Análisis mensual de defunciones, principales causas registradas y estado civil de los fallecidos.

Año
2019

Región
Todas

Sexo
Todas


Grupo de edad
Todas

Tipo de seguro
Todas


Total de Defunciones
114 mil

Promedio de edad
66


Evolución mensual de defunciones registradas



Top 5 causas principales de defunciones



Defunciones por estado civil



Análisis de muertes violentas:

Distribución de casos según tipo de muerte violenta, departamento y grupo de edad

Total de Defunciones

886 mil

Muertes violentas

36 mil

Año

Todas

Región

Todas


Sexo

Todas


Total de muertes violentas por departamento y grupo de edad

Departamento	Adolescente (13-17)	Adulto (18-60)	Anciano (61+)	Bebé (0-3)	Niño (4-12)	Total
AMAZONAS	10	89	21	5	7	132
ANCASH	77	992	290	63	40	1462
APURIMAC	44	479	130	39	32	724
AREQUIPA	115	1949	398	111	82	2655
AYACUCHO	66	460	99	43	44	712
CAJAMARCA	42	517	111	33	29	732
CALLAO	54	862	141	20	21	1098
Total	1739	25877	6030	1261	1145	36052

Total de casos por muertes violentas



Casos de muertes violentas por año



Esta vista analiza los registros clasificados como muertes violentas, considerando el tipo de evento, su distribución territorial, los grupos de edad afectados y su evolución anual.

Modelo analítico de clasificación:

Árbol de decisión para clasificar defunciones de ancianos y no ancianos.

Exactitud del modelo

67.90 %

Precisión

79.21 %


Recall

73.36 %

F1-score

76.18 %

Variables más importantes del modelo



Métricas de clasificación por clase

clase	Suma de precision	Suma de recall	Suma de f1_score	Suma de support
accuracy	0.68	0.68	0.68	0.68
Anciano	0.79	0.73	0.76	185,929.00
macro avg	0.63	0.64	0.63	265,818.00
No anciano	0.47	0.55	0.51	79,889.00
weighted avg	0.70	0.68	0.69	265,818.00
Total	3.27	3.29	3.27	797,454.68

Matriz de confusión

clase_real	Suma de predicho_no_anciano	Suma de predicho_anciano
Real_Anciano	49524	136405
Real_No_anciano	44089	35800
Total	93613	172205

Se aplicó un árbol de decisión para clasificar si una defunción correspondía a una persona anciana o no anciana. El modelo utilizó variables como sexo, región natural, tipo de seguro, tipo de lugar, necropsia y causa principal agrupada.